



UNIVERSITATEA DIN
BUCUREȘTI

FACULTATEA DE
MATEMATICĂ ȘI
INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

ANALIZA ȘI MODELAREA DATELOR COLECTATE PRIN EYE-TRACKING

Absolvent
Cocoșilă-Dumitriu Rareș

Coordonator științific
Conf. dr. Sergiu Nisioi

București, 2026

Rezumat

În această lucrare am analizat date de *eye-tracking* colectate la *Noaptea Cercetătorilor*, într-un experiment bazat pe jocul *Find Waldo*. Participanții au avut de găsit personajul în mai multe scene, iar privirea lor a fost înregistrată cu un *eye-tracker* Pupil Labs. Spre deosebire de un experiment de laborator, datele au fost obținute într-un mediu public, cu zgomot, întreruperi și diferențe mari între participanți. Din acest motiv, o parte importantă a tezei a fost transformarea înregistrărilor colectate într-un set de date utilizabil, prin segmentare pe niveluri, verificare manuală și filtrarea problemelor apărute în timpul colectării.

Pe baza acestor date, am extras metrice care descriu modul în care participanții caută personajul: timpul până la prima fixație pe Waldo (TTFF), numărul de fixații, acoperirea spațială, entropia privirii, entropia tranzițiilor între zone ale imaginii și raportul fixațiilor pe țintă. Am folosit apoi aceste metrice în două feluri. Mai întâi, am analizat traseele reale ale privirii și le-am comparat cu hărți de *saliency*, ca să verific dacă participanții urmăresc zonele evidente sau dacă își controlează căutarea în funcție de scopul jocului. După aceea, am folosit aceleași caracteristici în modele precum: regresie logistică, rețele MLP, o arhitectură BiLSTM cu mecanism de atenție și un model Markov de ordinul întâi pentru predicția următoarei zone privite.

Rezultatele arată că, în această sarcină, privirea nu este explicată suficient de elementele vizuale evidente din imagine. Participanții ignoră frecvent zonele puternic colorate dacă acestea nu ajută la găsirea personajului, ceea ce susține ideea unei căutări orientate pe scop. În același timp, analiza diferențelor individuale arată că participanții păstrează tipare proprii de explorare, vizibile în ritmul fixațiilor, acoperirea spațială și entropia traseului vizual, chiar și după ce ținem cont de dificultatea fiecărui nivel. Pentru partea de predicție, modelele simple au fost mai stabile pe setul de date disponibil, în timp ce modelele mai complexe au fost mai sensibile la dimensiunea redusă a datelor și la zgomotul din înregistrări.

Abstract

This thesis analyzes eye-tracking data collected during Researchers’ Night, in an experiment based on the Find Waldo game. Participants had to find the character in several scenes, while their gaze was recorded with a Pupil Labs eye-tracker. Unlike a laboratory experiment, the data was collected in a public setting, with noise, interruptions, and large differences between participants. For this reason, a significant part of the thesis was turning the collected recordings into a usable dataset, through level segmentation, manual validation, and filtering of the problems that appeared during data collection.

From these recordings, I extracted metrics such as time to first fixation on Waldo, number of fixations, spatial coverage, gaze entropy, transition entropy, and the proportion of fixations on the target. I used these metrics first to study how participants searched the images, and then as input features for predictive models. I also compared gaze paths against saliency maps to check whether participants were drawn to visually prominent regions or whether they guided their search more systematically toward the target. For modeling, I tested classical models like logistic regression, MLP networks, a BiLSTM architecture with an attention mechanism, and a first-order Markov model for predicting the next region a participant would look at.

The results suggest that gaze behavior in this task is not explained well by visual saliency alone. Participants often ignored visually strong regions when they were not useful for finding Waldo, which points to search being driven more by the goal of finding the character than by bottom-up visual reflexes. The data also showed individual differences between participants, especially in fixation rhythm, spatial coverage, and gaze-path entropy, and these differences remained visible even after controlling for level difficulty. For prediction, simpler models such as logistic regression and Markov chains were more stable than more complex neural models, likely because the dataset was small and noisy.

Cuprins

1	Introducere	5
1.1	Obiectivele tezei	6
1.2	Contribuții	7
2	Preliminarii și context științific	8
3	Pregătirea experimentului	10
4	Construirea setului de date	11
5	Preprocesare și analiza exploratorie a datelor	12
6	Analiza privirii participanților	16
7	Analiza strategiilor de căutare	18
8	Modelarea datelor	19
8.1	Rezultate și interpretare	21
9	Interpretabilitatea modelelor	22
10	Concluzii	24
	Bibliografie	25
A	Anexe	28
A.1	Rezultatele modelării	28
A.2	Coeficienții modelului liniar (Sarcina de succes)	29
A.3	Rezultate suplimentare pentru interpretabilitate	29
A.4	Verificări vizuale ale datelor	30
A.5	Matricele de tranziție spațială pe nivel	31
A.6	Rezultate suplimentare pentru diferențele individuale	32

1 Introducere

Eye-tracking-ul permite observarea directă a modului în care o persoană explorează vizual o scenă. În loc să analizăm doar rezultatul final al unei sarcini, putem urmări traseul privirii, zonele în care participantul revine, timpul până la prima fixație pe țintă și felul în care atenția se mută între regiuni ale imaginii [21, 10]. În cazul jocului *Find Waldo*, aceste informații sunt utile deoarece participanții trebuie să caute activ un personaj într-o imagine aglomerată. Astfel, putem analiza atât comportamente orientate de scopul sarcinii, de tip *top-down*, cât și comportamente influențate de elemente vizuale evidente, de tip *bottom-up* [9, 12, 20]. Ulterior, traseele vizuale extrase pot fi transformate în serii temporale și în date structurate, pe baza cărora se pot aplica metode de analiză și modelare.

Prezenta lucrare de licență se încadrează în domeniile analizei de date și a învățării automate (*Machine Learning*). Alegerea acestei teme a venit ca o urmare a participării de la Noaptea Cercetătorilor și din necesitatea de a înțelege datele colectate. Din acest motiv, contribuția proprie a început cu mult înaintea scrierii codului, prin pregătirile realizate pentru eveniment, unde am testat mai multe experimente. Inițial, am luat în considerare sarcini de citire și înțelegere a textului, apoi urmărirea unor instrucțiuni audio pe materiale video sau teste de tip *human benchmark*. În cele din urmă, am ales experimentul *Find Waldo*, deoarece se potrivea cel mai bine contextului: este o activitate interactivă pentru un public divers (copii și adulți), oferind în același timp posibilitatea de a colecta date relevante pentru studiu.

Rolul meu a fost unul tehnic, concentrat pe configurarea modului de lucru, calibrarea echipamentului și colectarea efectivă a datelor. În plus, pentru public am creat un *setup* interactiv cu multiple ecrane. Unul dintre ecrane afișa perspectiva participantului care purta *eye-tracker*-ul, având suprapus un indicator ce reprezenta locul în care privește acesta. Un al doilea ecran rula un *dashboard* cu grafice actualizate în timp real, ce oferea statistici precum: coordonatele privirii, viteza de mișcare oculară, fixațiile și sacadele. De asemenea, la finalul unor sesiuni, prezentam participanților care erau curioși de rezultate un feedback direct folosind *Neon Player*, înlocuind temporar graficele cu hărți de atenție

(*heatmaps*) și traiectoriile vizuale (*gazeaths*) generate pe baza nivelurilor tocmai încheiate. Astfel, munca mea a asigurat atât infrastructura pentru afișarea informațiilor către public, cât și colectarea datelor.

1.1 Obiectivele tezei

Teza urmărește două obiective principale. Primul este construirea unui sistem de prelucrare pentru datele colectate cu *eye-tracker*-ul, pornind de la înregistrări și ajungând la un set de date segmentat pe niveluri, verificat manual și descris prin metrici numerice. Acest pas este important deoarece datele nu provin dintr-un experiment controlat de laborator, ci dintr-un eveniment public, unde apar inevitabil sesiuni incomplete, zgomot, diferențe între participanți și momente în care calitatea înregistrării scade.

Al doilea obiectiv este folosirea acestor metrici pentru a analiza comportamentul vizual. Ne interesează, pe de o parte, dacă participanții urmăresc zonele evidente ale imaginii sau dacă își controlează privirea în funcție de scopul sarcinii. Pe de altă parte, verificăm dacă primele secunde ale unei sesiuni conțin suficientă informație pentru a anticipa succesul, durata căutării sau următoarea zonă privită.

Structura tezei urmărește pașii prin care am ajuns de la colectarea datelor la analiza și modelarea lor. *Secțiunea 2* introduce contextul și conceptele teoretice legate de atenția vizuală și mișcările oculare. *Secțiunea 3* prezintă detalii despre organizarea experimentului și procesul de colectare a datelor. *Secțiunea 4* descrie pașii de adnotare și verificare a înregistrărilor, pas necesar pentru validarea și analiza datelor. După obținerea datelor curate, *Secțiunea 5*, respectiv *Secțiunea 6* cuprind etapele de preprocesare, analiza exploratorie a datelor (*EDA*) și etapele ulterioare de analiză. În aceste secțiuni, voi detalia metricile extrase, comportamentul și tiparele observate, voi face comparația bazată pe *saliency* și voi discuta concluziile rezultate din teste. *Secțiunea 7* analizează strategiile de căutare, investigând dacă participanții își păstrează un stil individual de explorare vizuală, independent de dificultatea inerentă a nivelului. *Secțiunea 8* prezintă în detaliu modelele de inteligență artificială folosite pe datele extrase pentru a rezolva task-urile specifice, comparații între modurile lor de funcționare și rezultatele pe datele noastre.

Secțiunea 9 prezintă analiza de interpretabilitate și stabilitate, prin care verificăm ce caracteristici influențează deciziile modelelor și cât de stabile sunt rezultatele la eliminarea datelor zgomotoase. În final, Secțiunea 10 sintetizează concluziile și limitările întregului proiect.

1.2 Contribuții

Contribuțiile sunt împărțite în trei direcții:

Pe partea experimentală, m-am implicat direct în dezvoltarea modului de colectare a datelor la Noaptea Cercetătorilor. După eveniment, am construit pașii de segmentare, adnotare și verificare manuală, pas esențial prin care am reușit să transform înregistrările obținute de la *eye-tracker* într-un set de date utilizabil.

Din punct de vedere al analizei, am realizat explorarea datelor prin extragerea unor metrici spațio-temporale: timpul până la prima fixație pe Waldo, entropia spațială, entropia de tranziție, acoperirea spațială și raportul fixațiilor pe Waldo. Am folosit aceste metrici pentru a analiza de ce anumite scene din joc sunt mai dificile și modul cum își schimbă participanții strategiile de explorare în funcție de nivel. În aceeași etapă, am generat hărți de atenție și le-am comparat cu hărțile de *saliency* pentru a evalua raportul dintre reflexele vizuale și controlul cognitiv orientat pe scopul de a găsi personajul.

Mai departe, m-am ocupat de partea de modelare a datelor. În acest sens, am construit mai multe modele de inteligență artificială: tabulare (folosind Regresia Logistică și rețelele MLP), recurente (*BiLSTM* pe ferestre de timp) și modele Markov de ordin întâi pentru anticiparea următoarei regiuni la care se va uita un participant. Pentru fiecare variantă am rulat experimente și am urmărit dacă rezultatele rămân stabile. Pe lângă acestea, am evaluat diferențele stilurilor de explorare vizuală specifice fiecărui participant. Mai mult, am adăugat o analiză de interpretabilitate (*feature and sensitivity analysis*) pentru modelele antrenate, care arată ce atribute influențează deciziile algoritmilor. Astfel, rezultatele obținute pot fi interpretate și din perspectiva comportamentului vizual, nu doar ca scoruri de clasificare.

2 Preliminarii și context științific

Studiul datelor colectate prin *eye-tracking* se bazează pe ipoteza *eye-mind*, conform căreia zonele în care privirea se oprește oferă informații despre procesele cognitive la momentul respectiv [10]. Din punct de vedere tehnic, un traseu vizual (*gaze-path*) nu funcționează ca un flux continuu, ci mai degrabă este o alternanță între *fixații* (acele perioade de timp în care ochiul rămâne relativ nemișcat pentru a observa detaliile dintr-o regiune) și *sacade* (salturile rapide dintre două zone de interes, în timpul cărora vederea este suprimată). Într-o sarcină de căutare vizuală, precum *Find Waldo*, înțelegerea și separarea acestor evenimente sunt necesare pentru a realiza o analiză corectă. Pentru a analiza matematic comportamentul participanților, trebuie efectuată trecerea de la o secvență continuă de coordonate la o secvență de stări discrete. Doar astfel putem măsura suprafața acoperită de privire, ordinea în care sunt inspectate zonele ecranului și interacțiunea directă cu personajul căutat.

Dincolo de extragerea acestor evenimente, un aspect important în studiul căutării vizuale este înțelegerea modului în care participanții își folosesc atenția pentru a rezolva sarcinile impuse. În acest sens, facem distincția între două tipuri de mecanisme: o căutare bazată pe reflexul vizual, numită *bottom-up*, și căutarea orientată pe scopul sarcinii, numită *top-down*. Modelele ce analizează caracteristicile vizuale ale unei scene (*saliency-maps*), precum algoritmul clasic Itti-Koch, calculează elemente ce determină mecanismul *bottom-up*, pornind strict de la imagine, precum intensitatea (contrastul), culoarea și orientarea conturilor (de exemplu, o muchie ascuțită sau o formă geometrică poate atrage privirea) [9]. Cu toate acestea, atunci când există un obiectiv clar pentru participanți, cum este găsirea personajului, intenția de a rezolva sarcina ajunge să controleze mișcările ochilor mult mai mult decât reflexele vizuale [6]. Pentru a putea măsura și evalua acest fenomen, trebuie să comparăm modul efectiv în care participanții au privit scenele cu hărțile de *saliency* generate. Pentru ca această comparație să fie corectă, trebuie să folosim metrici de evaluare precum *Normalized Scanpath Saliency* sau *Information Gain*. Mai mult, rezultatele obținute trebuie raportate la un model de referință de bază, cum este *center bias*, ce reprezintă tendința naturală a oamenilor de a privi direct spre centrul ecranului,

indiferent de ce fel de imagine este afișată [2].

O altă direcție relevantă este aplicarea teoriei informației pentru a înțelege mai bine explorarea vizuală. Numărul de fixații nu este suficient pentru a descrie o strategie de căutare, deoarece două persoane pot avea același număr de fixații, dar trasee vizuale foarte diferite. De aceea, sunt utile conceptele de entropie spațială și entropie de tranziție. Cea spațială arată cât de răspândite sunt fixațiile pe imagine, iar cea de tranziție arată cât de previzibile sunt trecerile dintre zonele ecranului. Aceste metrice sunt potrivite pentru o sarcină de tip *Find Waldo*, unde dificultatea nivelului poate schimba modul în care participantul explorează scena [12].

Nu în ultimul rând, o abordare tot mai folosită este trecerea de la simpla analiză statistică către modelarea prin *Machine Learning*. Traseele vizuale sunt tratate fie ca serii de timp, fie ca date secvențiale. O direcție foarte utilă este prezicerea următoarei regiuni spre care se va uita un participant, folosind modele bazate pe lanțuri Markov, lucru care ne ajută să anticipăm pas cu pas mișcările următoare ale privirii. O altă abordare presupune folosirea rețelelor recurente (precum *LSTM*). Aceste rețele păstrează informația despre ordinea fixațiilor, ceea ce le permite să surprindă diferența dintre o căutare care se apropie treptat de personaj și una în care participantul rămâne blocat în zone irelevante ale imaginii. În final, aceleași date ne permit să facem distincții clare între participanți, pe baza comportamentului vizual unic al fiecăruia.

Aceste concepte formează baza pentru restul lucrării: metricile extrase din traseele vizuale vor fi folosite atât pentru analiza comportamentului de căutare, cât și pentru antrenarea și evaluarea modelelor pe datele colectate.

3 Pregătirea experimentului

O parte importantă a proiectului a constat în pregătirea efectivă a experimentului pentru Noaptea Cercetătorilor. Împreună cu echipa, am configurat *setup*-ul și am selectat imaginile pentru nivelurile jocului. După alegerea scenelor, ne-am concentrat pe testarea întregului sistem pentru a ne asigura că funcționează corect. Concret, am verificat dacă *eye-tracker*-ul înregistrează și transmite datele corect către sistem, dacă funcționează toate ecranele și dacă publicul poate urmări statisticile în timp real. Pentru că așteptam mulți participanți și timpul era limitat, interacțiunea trebuia să fie simplă: participantul să poată începe jocul rapid, fără explicații lungi.

Modul în care am desfășurat experimentul se observă direct în datele obținute, atât prin avantaje, cât și prin limitări. Avantajul principal este că am colectat date de la un public divers, într-un mediu real. Pe de altă parte, agitația de la eveniment a adus și zgomot în înregistrări: unii participanți au făcut mișcări bruște, au mai existat întreruperi, iar calibrarea *eye-tracker*-ului a trebuit refăcută de mai multe ori pentru anumite persoane. Prin urmare, aceste probleme au trebuit să fie tratate ulterior, într-o etapă separată de curățare și preprocesare a datelor.

La nivel practic, am urmărit recomandările din studiile de *eye-tracking* [3] și am pus la punct câteva detalii legate de *setup*, pentru a obține înregistrări cât mai bune. Am urmărit menținerea unei distanțe constante între participant și monitor. Acest lucru este esențial nu doar pentru acuratețea datelor înregistrate de *eye-tracker* [3], ci mai ales pentru ca markerele lipite pe colțurile ecranului să rămână constant vizibile pe filmare, un pas obligatoriu în delimitarea corectă a regiunii de interes (ROI). De asemenea, pentru a evita oboseala, mai ales că o bună parte din public era formată din copii, am limitat timpul de joc și numărul de imagini pe care le parcurgea o singură persoană. Practic, am încercat să creăm un mediu de colectare cât mai stabil, care să compenseze pe cât posibil lipsa condițiilor de laborator.

În final, am obținut consimțământul participanților care au fost de acord cu folosirea și prelucrarea ulterioară a datelor în mod anonimizat. Figura 1 ilustrează atât etapa de pregătire a experimentului, cât și desfășurarea colectării în cadrul evenimentului.



(a) Pregătirea experimentului



(b) Colectarea datelor la eveniment

Figura 1: Cadre surprinse în timpul pregătirii și desfășurării evenimentului.

4 Construirea setului de date

Primul pas în obținerea setului de date a fost filtrarea înregistrărilor pe baza conștiințământului, în urma căreia am reținut 11 participanți dintr-un total de 35 care au jucat inițial. Cum fiecare persoană a jucat toate cele 4 niveluri, au rezultat în total 44 de secvențe de date de joc. Următoarea etapă a constat în prelucrarea acestor înregistrări. Mai întâi, am determinat dimensiunile imaginilor aferente fiecărui nivel prin raportarea la regiunea delimitată de markerele de pe ecran. Folosind această mapare, am corectat și recalculat metricile extrase din datele *eye-tracker*-ului Pupil Labs Neon [15].

Mai departe, a trebuit să extragem datele relevante. Am delimitat *timestamp*-urile de început și de sfârșit pentru fiecare nivel în parte, astfel încât intervalul să corespundă cât mai bine timpului efectiv de joc. În cadrul acestor intervale, am făcut o verificare suplimentară: ori de câte ori participantul privea în afara scenei, acea porțiune de date a fost eliminată, iar în analiză au fost păstrate doar momentele în care participantul era atent la joc. Ultimul pas a fost marcarea coordonatelor personajului la fiecare nivel, lucru care ne ajută să știm precis dacă și când a fost găsit.

Astfel, la finalul acestui proces de curățare, am obținut structura finală a setului de date: avem 11 participanți cu vârste cuprinse între 5 și 20 de ani (mai exact, 6 copii, 4 adolescenți și un singur adult), care au generat acele 44 de secvențe de-a lungul celor 4 niveluri jucate.

Chiar dacă aceste date permit o analiză statistică a modului în care au reacționat participanții la fiecare nivel, trebuie luate în considerare și limitările. Numărul mic de secvențe și distribuția dezechilibrată a vârstelor arată că nu avem un volum suficient de date pentru a antrena de la zero modele complexe de *Machine Learning*.

5 Preprocesare și analiza exploratorie a datelor

Pentru a transforma înregistrările într-un format utilizabil în analiză, procesarea a urmărit două direcții principale.

Prima s-a concentrat pe evaluarea interacțiunilor vizuale cu personajul. Mai exact, analizând fixațiile din intervalele de timp ale fiecărui nivel, am urmărit să identificăm momentele în care privirea a intersectat regiunea de interes (Waldo). Am delimitat exact zona (*bounding box*) pentru personaj, iar intersecțiile directe au fost marcate ca atare. Pentru a capta și contactul periferic (momentele în care participantul se uita fix lângă personaj, dar nu direct pe el), am extins această zonă cu o marjă suplimentară de 1.25% pe toate axele coordonatelor normalizate.

Mai departe, am preluat aceste fixații, alături de celelalte date, pentru a construi un set extins de caracteristici pentru fiecare nivel. Obiectivul aici nu a fost doar să măsurăm performanța, ci să cuantificăm modul în care participanții au explorat imaginea. Astfel, pe lângă metricile standard (cum ar fi durata de joc, numărul total de fixații sau timpul până la prima fixare pe Waldo), am extras și *timpul de verificare* (câte secunde a continuat participantul să analizeze personajul după ce l-a observat prima oară, pentru a-și confirma decizia). În plus, am vrut să vedem cât de lung a fost traseul vizual (însumând distanțele euclidiene ale tuturor sacadelor) și ce suprafață totală a acoperit. Pentru distribuția fixațiilor, am calculat aria *Convex Hull* și dispersia pe axele x și y . De asemenea, pentru a face diferența între o căutare organizată și una haotică, am măsurat cât de împrăștiate au fost fixațiile (entropia spațială) și cât de previzibil a fost traseul privirii dintr-o zonă în alta a ecranului (entropia de tranziție). La finalul acestei etape de calcul am obținut tabela completă de date pe care s-au bazat analizele ulterioare.

Pentru a măsura cât de împrăștiată a fost privirea pe parcursul căutării (entropia

spațială pe zone) și cât de previzibile au fost trecerile dintr-o zonă în alta (entropia de tranziție), am împărțit ecranul în 16 zone egale (într-un format de 4×4). Am mers pe această variantă pentru că arată acele părți dintr-o imagine care au captat atenția, dar ne și asigură că fiecare parte strânge suficiente fixații pentru a avea un calcul valid. Dacă am fi tăiat ecranul în bucăți mai mici, am fi avut multe zone complet goale, ceea ce ar fi făcut rezultatele instabile, mai ales având în vedere numărul restrâns de participanți.

Pentru această împărțire, am calculat, pe baza abordării lui Shannon [17], entropia spațială astfel:

$$H_s = - \sum_k p_k \log_2 p_k$$

unde p_k reprezintă proporția de fixații care aparțin zonei k . Mai departe, pentru a vedea cât de ușor este să anticipezi traseul privirii dintr-o zonă în alta (o numim entropia de tranziție), am folosit probabilitățile condiționate:

$$H_t = - \sum_i p(i) \sum_j p(j | i) \log_2 p(j | i)$$

Pentru a calcula timpul până la prima fixație pe Waldo, am folosit diferența dintre *times-tamps* înregistrate:

$$\text{TTF} = t_{\text{prima fixație pe Waldo}} - t_{\text{început nivel}}$$

O fixație este considerată pe Waldo dacă punctul ei se află în zona extinsă (cu marja de 1.25%). Astfel, măsurăm primul contact vizual cu Waldo, inclusiv cel periferic, și nu neapărat momentul în care participantul recunoaște personajul. Acest lucru explică de ce, la nivelurile grele, căutarea continuă zeci de secunde după prima înregistrare a privirii pe țintă.

Dincolo de aceste calcule numerice, am folosit algoritmul *DBSCAN* [4] pentru a identifica zonele în care fixațiile s-au concentrat repetat. Am extras două tipuri de clustere: unele asociate contactului cu Waldo și altele aflate în afara zonei personajului. Folosesc aceste clustere doar pentru a verifica etapa de preprocesare, fără ca ele să devină un rezultat separat de modelare.

Prima observație din rezultate este că nivelurile diferă ca dificultate. Așa cum arată

mediile din Tabela 1, `waldo_1` este cel mai solicitant ca durată medie, de peste 100 de secunde, în timp ce `waldo_2` este rezolvat, în medie, în doar 10 secunde. Totuși, dacă privim strict timpul până la prima fixație, `waldo_3` are cel mai mare timp (30.69 s față de 24.92 s). Asta arată că `waldo_3` este cel mai greu de localizat inițial, chiar dacă, odată reperat, este confirmat mult mai rapid. Testele ANOVA pe duratele log-transformate susțin această diferență între niveluri, atât pentru timpul total de căutare ($p \approx 5.8 \times 10^{-6}$), cât și pentru timpul până la prima fixație pe Waldo ($p \approx 0.00295$). Această dificultate este vizibilă și în metrica *Raport Waldo* în tabel. Metrica arată proporția fixațiilor care s-au aflat direct pe personaj din numărul total de fixații înregistrate pe durata nivelului. La nivelul ușor, peste 15% din fixațiile jucătorilor ajung direct pe personaj. La nivelul dificil, raportul scade la aproximativ 3.5%, ceea ce sugerează că participanții petrec relativ puțin timp fixând direct personajul și explorează mai mult restul imaginii.

Tabela 1: Rezumat pe nivel pentru metricile analizei exploratorii.

Nivel	Durată medie (s)	TTFF mediu (s)	Entropia privirii	Entropie tranziții	Raport Waldo
<code>waldo_1</code>	108.26	24.92	7.33	1.65	0.035
<code>waldo_2</code>	10.15	3.15	4.88	0.93	0.155
<code>waldo_3</code>	40.58	30.69	5.95	1.26	0.033
<code>waldo_4</code>	26.73	4.65	4.72	1.12	0.106

De asemenea, o entropie de tranziție aproape dublă la primul nivel sugerează că traseul privirii devine mai variabil între zone atunci când personajul nu este găsit rapid.

Mergând mai departe la corelații (Figura 2 și Tabela 2), evaluate folosind coeficientul Spearman și corectate pentru teste multiple prin metoda Holm-Bonferroni [7], se observă o legătură puternică dintre timpul de căutare și entropia privirii ($\rho \approx 0.964$). Totuși, acest scor arată o redundanță mare în date: durata, numărul de puncte de privire și entropia privirii au corelații cuprinse între 0.93 și 1.00. Aici este important să nu tragem concluzii greșite: o entropie mare nu înseamnă neapărat că participantul a fost complet dezorientat sau că a privit haotic. Explicația este, de fapt, mult mai simplă. Când o căutare durează mult, participantul are pur și simplu timp să își plimbe privirea prin toate zonele ecranului. Astfel, fixațiile ajung să se împrășteie uniform pe toată suprafața

imaginii, ceea ce crește automat valoarea entropiei.




Figura 2: Corelațiile Spearman dintre metrici. Căutările lungi sunt asociate cu o explorare extinsă și cu un raport mult mai mic de fixații pe Waldo.

Tabela 2: Corelațiile dintre durata totală a căutării și restul metricilor, alături de validare (valori p ajustate Holm).

Metrică corelată cu durata	Spearman ρ	p_{Holm}
TTFF	0.606	0.0012
entropia privirii	0.964	1.14×10^{-23}
Entropie tranziții	0.808	5.01×10^{-10}
Raport Waldo	-0.338	0.0861

Pentru a înțelege mai bine dificultatea acestor căutări, am rulat și o analiză de eșec (*failure analysis*). Am selectat secvențele în care timpul de căutare a depășit mediana nivelului, iar contactul cu personajul a fost redus (cel mult o fixație pe Waldo sau un raport al fixațiilor pe Waldo sub mediana setului). Această filtrare a identificat 13 secvențe: 5 pentru `waldo_1`, 5 pentru `waldo_3`, 2 pentru `waldo_4` și 1 pentru `waldo_2`. Aceste cazuri sugerează că un timp de căutare ridicat nu înseamnă automat o scanare a imaginii, ci

poate indica un blocaj în strategia de căutare.

Mai departe, analizând datele (în anexă, Figura 5), observăm o calitate ridicată a înregistrărilor. Deși lucrul cu *eye-tracker*-ul în scenarii reale generează inevitabil zgomot, graficul indică un nivel redus de erori. Erorile, fie că vorbim de fixații și puncte de privire înregistrate în afara ecranului, fie de date cu un grad scăzut de încredere, sunt minime, situându-se în general sub pragul de 7% per participant.

Un alt aspect pe care l-am urmărit a fost cât de constanți s-au menținut participanții de la un nivel la altul. Dacă ne uităm la durata de căutare, graficul, care este inclus în anexă (Figura 6), arată diferențe clare de comportament. În partea stângă îi avem pe cei care au scos timpi asemănători, indiferent de nivel. În partea dreaptă, în schimb, variațiile sunt mult mai mari: aici sunt participanții care au terminat imediat nivelurile ușoare, dar pe cele grele au pierdut zeci de secunde până să îl găsească pe Waldo. Asta arată că nu putem să împărțim pur și simplu jucătorii în rapizi și lenți. Timpul lor depinde foarte mult de dificultatea fiecărui nivel în parte, nu doar de reflexele pe care le au.

Pe lângă datele din tabele, am generat și hărți de atenție (KDE) pentru fiecare participant și nivel în parte, pentru a ne asigura că datele obținute au sens. Am verificat că zonele unde s-au concentrat fixațiile se potrivesc cu conținutul nivelului, că scripturile au prins corect momentul în care privirea a ajuns pe Waldo și, nu în ultimul rând, pentru a observa ce alte elemente de pe ecran le-au atras atenția. Un exemplu de astfel de verificare este prezentat în Figura 7 din anexe.

6 Analiza privirii participanților

Scopul acestei etape este să înțelegem ce anume influențează zonele în care se uită participanții într-un nivel. Acționează ei dintr-un reflex vizual (*bottom-up*), fiind atrași de culorile și elementele contrastante de pe ecran, sau își controlează activ privirea pentru a găsi personajul (*top-down*)?

Pentru a testa acest lucru, am implementat un model computațional de tip Itti-Koch [9] care generează hărți de proeminență vizuală (*saliency*). Algoritmul procesează fiecare imagine pe mai multe canale separate. Pentru intensitate și culoare, am comparat zone lo-

cale cu vecinătatea lor pentru a evidenția regiunile care ies în contrast față de fundal. Am detectat orientarea muchiilor cu filtre Gabor pe patru direcții ($0^\circ, 45^\circ, 90^\circ, 135^\circ$) și densitatea lor cu algoritmul Canny. Pe lângă acestea, având în vedere aspectul personajului Waldo (bluza cu dungi roșii), am implementat și o altă euristică. Am adăugat un canal de *color popout*, transformând imaginea în spațiul HSV și izolând pixelii cu nuanțe puternice de roșu, ceea ce avantajează modelul printr-un indiciu legat de țintă. Toate aceste canale au fost normalizate și combinate ponderat într-o singură hartă globală de *saliency* pentru fiecare nivel, punând în evidență zonele care atrag atenția cel mai puternic.

Peste aceste hărți, am suprapus coordonatele traseelor vizuale reale și am calculat trei metrici pentru evaluare. Prima este *NSS* (Normalized Scanpath Saliency) [2]. Pentru această metrică, harta de *saliency* este standardizată, astfel încât media să fie zero și deviația standard să fie 1. Apoi, pentru fiecare fixație, extragem valoarea hărții în punctul respectiv și calculăm media acestor valori. Un scor *NSS* pozitiv înseamnă că fixațiile cad, în medie, pe zone mai contrastante decât restul imaginii. În datele noastre, scorurile pozitive arată că privirea participanților se intersectează pe alocuri cu elementele intens colorate, dar nu suficient pentru a explica singure traseele vizuale.

Pe lângă *NSS*, am verificat rezultatul și prin metrica *AUC-Judd* (prezentă în Figura 3b). Aceasta tratează harta de *saliency* ca pe un clasificator binar care trebuie să separe punctele fixate real de puncte alese aleatoriu din imagine. În cazul nostru, am comparat pixelii fixați de participanți cu un set de 2000 de coordonate generate aleatoriu. Un scor apropiat de 0.5 ar însemna o separare aproape aleatoare, iar un scor apropiat de 1 ar indica o separare foarte bună. Rezultatele *AUC-Judd* confirmă tendința *NSS*: modelul diferențiază fixațiile de zgomotul aleator, dar cu o performanță moderată.

Totuși, diferența devine mai clară la a treia metrică, *Information Gain* (IG) [2]. Aceasta evaluează modelul Itti-Koch comparându-l cu un model de referință extrem de simplu: o distribuție gaussiană plasată direct în mijlocul ecranului (*center bias*), care pleacă de la premisa că participanții privesc natural spre centrul imaginii. Concret, pentru fiecare fixație, comparăm probabilitatea acordată de harta de *saliency* cu probabilitatea acordată de modelul *center bias*. Dacă valoarea IG este pozitivă, harta de *saliency* explică fixațiile

mai bine decât modelul de centru. Dacă valoarea este negativă, modelul de centru este mai bun. Deoarece pe datele noastre IG are media -0.226 și deviația standard 0.584 , iar mediana este -0.207 , observăm că modelul de referință depășește modelul Itti-Koch.

Mai simplu spus, rezultatele sugerează că participanții nu urmăresc automat zonele cele mai contrastante ale imaginii. Împreună cu ablația din Secțiunea 9, acest rezultat este compatibil cu o căutare ghidată de scopul sarcinii. Tocmai de aceea, gradul în care traseul privirii se aliniază (sau nu) cu aceste hărți rămâne o caracteristică pe care o includem printre datele de intrare ale modelelor ulterioare, urmând să evaluăm în Secțiunea 8 dacă aduce într-adevăr informație utilă sau dacă se comportă ca zgomot.




Figura 3: Comparația directă între zonele de *saliency* (zonele estimate ca fiind cele mai contrastante vizual) și traseul real al privirii.

7 Analiza strategiilor de căutare

În această secțiune am evaluat dacă participanții își păstrează un stil individual de explorare vizuală, independent de dificultatea fiecărui nivel. Obiectivul este să verificăm dacă aceste diferențe rămân constante în comportamentul de căutare. Pentru a verifica acest lucru, am urmărit variațiile exprimate prin ritmul fixațiilor, acoperirea spațială, entropia explorării și timpul petrecut în zona personajului.

Pentru această etapă am normalizat caracteristicile în interiorul fiecărui nivel. Astfel, ne asigurăm că diferențele dintre participanți nu sunt confundate cu gradul de dificultate al nivelului.

Rezultatele arată că diferențele dintre participanți rămân vizibile chiar și după ce con-

trolăm dificultatea nivelului. Cele mai vizibile diferențe apar la rata fixațiilor, lungimea traseului raportată la timp, proporția timpului petrecut pe Waldo, entropia spațială și acoperirea vizuală. Pentru a măsura acest lucru, am comparat două modele simple: unul care explică variația unei metrici folosind doar nivelul și unul care adaugă și participantul. Scorul R^2 arată ce proporție din variație este explicată de model. De exemplu, în cazul ratei fixațiilor, adăugarea participantului crește scorul R^2 cu aproximativ 0.640. Asta sugerează că ritmul de explorare este în primul rând o trăsătură individuală a participantului, nu doar o reacție la designul scenei.

Pentru a valida aceste observații, am rulat o clasificare pe caracteristicile normalizate. Folosind cele mai informative patru trăsături selectate de clasificator (rata fixațiilor, lungimea traseului raportată la timp, timpul petrecut pe țintă și entropia spațială), *balanced accuracy* (adică media acurateților calculate separat pentru fiecare participant) ajunge la 0.318, vizibil peste pragul de 0.091 (11 participanți). Acest scor sugerează că diferențele individuale există și pot fi captate algoritmic prin metrici de bază, așa cum se poate observa în anexe (Figura 9).

8 Modelarea datelor

După analiza modului în care participanții privesc fiecare nivel, urmează etapa de predicție. Scopul este să anticipăm dacă un jucător va găsi personajul sau dacă va avea o căutare lungă, folosind doar primele cinci secunde din înregistrare. Considerăm, mai departe, că succesul înseamnă identificarea personajului pe parcursul întregului nivel, iar căutarea lungă este definită relativ la durata mediană a nivelului.

Implementarea s-a bazat pe bibliotecile standard Python folosite pentru date și *Machine Learning* [5, 8, 11, 13, 14, 16, 18, 19] și pe OpenCV [1] pentru procesarea imaginilor.

Pentru a evita supraevaluarea performanței și riscul de *overfitting*, am folosit o validare de tip *leave-one-participant-out*. Astfel, datele unui participant nu au fost folosite simultan atât pentru antrenare, cât și pentru testare. Pentru că setul de date este dezechilibrat (avem mai multe succese decât eșecuri), am calculat o pondere pentru clasa pozitivă (*positive weight*), notată cu w , pe baza raportului dintre numărul de exemple negative

și pozitive din setul de antrenare, care a fost integrată în funcția de pierdere Binary Cross-Entropy (BCE), aplicată asupra logiturilor generate de model. Formal, funcția se definește astfel:

$$L(y, \hat{z}) = -[w \cdot y \log \sigma(\hat{z}) + (1 - y) \log(1 - \sigma(\hat{z}))]$$

unde y este eticheta reală, $\hat{z}$ reprezintă logitul produs de model, iar $\sigma(\cdot)$ este funcția sigmoid.

Am testat trei tipuri de modele:

1. Algoritmi clasici

Aici am extras din ferestrele de timp un set de 18 caracteristici statice (*gaze only*), precum rata fixațiilor, entropia sau alinierea cu harta de *saliency*. Am testat și o variantă extinsă în care am adăugat date despre contactul direct cu personajul. Am testat următoarele modele:

- O regresie logistică, optimizată cu Adam (learning rate 0.01).
- Un Multi-Layer Perceptron simplu, cu un singur strat ascuns de 32 de neuroni. Am folosit ReLU ca funcție de activare și un strat de Dropout de 15% pentru a reduce riscul de *overfitting*.

2. Modele pe serii de timp

În această abordare, datele au fost tratate ca serii de timp. La fiecare pas s-a extras un vector de nouă caracteristici (coordonate, viteză, accelerație, unghi și valoarea de *saliency*), iar secvențele au fost aduse la 60 de pași prin *padding*, excluzând de la procesare zerourile adăugate artificial. Au fost evaluate două modele:

- **Time-Averaged MLP:** Un model simplu care filtrează pașii de *padding*, calculează media caracteristicilor în timp și trimite rezultatul către un MLP pentru clasificare.
- **BiLSTM + Attention:** Modelul folosește o rețea BiLSTM cu 64 de neuroni în stratul ascuns, ale cărei ieșiri sunt ponderate printr-un mecanism de atenție. Pentru a evita influențarea predicției, elementele de *padding* sunt excluse din calcul înainte de aplicarea funcției *Softmax*, astfel încât rețeaua să aloce importanță doar fixațiilor

reale.

3. Modele de tranziție (Predicția mișcării)

În această abordare, am urmărit să anticipăm în ce zonă a ecranului se va muta privirea. Pentru a realiza acest lucru, am împărțit imaginea într-o grilă 2×2 (4 cadrane). Folosind locația curentă, locația anterioară și dinamica sacadei, modelul trebuie să prezică următorul cadran vizitat. Am comparat o arhitectură MLP cu un model statistic: un Lanț Markov de ordinul întâi, care calculează direct matricea probabilităților de tranziție dintr-un cadran în altul. Matricele de tranziție per nivel sunt prezentate în Figura 8 din anexe.

Pentru evaluare am folosit *balanced accuracy* ca metrică principală, deoarece setul de date este dezechilibrat. Această metrică calculează media dintre rata de recunoaștere a clasei pozitive și rata de recunoaștere a clasei negative:

$$\text{Balanced Accuracy} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)$$

unde TP și TN sunt predicțiile corecte pentru clasele pozitivă și negativă, iar FP și FN sunt erorile de clasificare. Spre deosebire de acuratețea simplă sau de scorul F1, *balanced accuracy* penalizează modelele care prezic aproape mereu clasa majoritară și ignoră clasa mai rară.

8.1 Rezultate și interpretare

Pentru predicția succesului, regresia logistică antrenată pe caracteristici extinse (*gaze+target*) a obținut cel mai bun rezultat, cu un *balanced accuracy* de 0.705 și un scor F1 de 0.814, ceea ce arată că informația despre contactul direct cu personajul este foarte importantă. Varianta *gaze+target* folosește și informația că privirea a ajuns pe Waldo în primele secunde, deci nu măsoară doar dinamica generală a privirii. În contrast, pentru anticiparea unui blocaj (căutare lungă), adăugarea acestor date nu ajută rezultatul, iar varianta bazată exclusiv pe explorare spațială obține rezultate mai bune. Totuși, fără informația de contact, regresia logistică pentru predicțiile succesului are un *balanced*

accuracy scăzut (0.459), semn că trăsăturile de explorare nu reușesc să separe singure succesul de eșec, pe setul nostru de date.

Mai departe, în ceea ce privește seriile de timp, modelul care face media caracteristicilor pe fereastra de timp (*Time-Averaged MLP*) a obținut scoruri mai bune, cel mai bun scor fiind de 0.792 la predicția căutărilor lungi. În paralel, arhitectura avansată *BiLSTM* a obținut scoruri mai slabe în toate testele (0.511 la predicția succesului și 0.589 la predicția căutării lungi). O explicație ține de volumul redus al datelor: rețeaua recurentă, având mai mulți parametri și o capacitate mai mare, a ajuns rapid la *overfitting*, în ciuda regularizării aplicate.

În final, pentru predicția următoarei mișcări, abordarea lanțului Markov de ordinul 1 (0.643) depășește atât rețeaua neuronală (*MLP pentru Tranziție* - 0.586), cât și predicția majoritară, susținând utilitatea matricelor de tranziție extrase.

Această alegere este importantă în interpretarea rezultatelor noastre: un clasificator de tip majoritar atinge un scor F1 ridicat, de 0.849, fără a prezice niciun eșec. În acest caz, scorul F1 supraestimează performanța reală, în timp ce *balanced accuracy* arată mai clar dacă modelul separă ambele clase.

Scorurile din Tabela 3, aflată în anexe, sunt calculate pe baza tuturor predicțiilor adunate din cele 11 fold-uri de leave-one-participant-out.

9 Interpretabilitatea modelelor

Pentru a verifica dacă modelele folosesc tipare relevante de comportament și nu doar zgomotul din date, am realizat o analiză de interpretabilitate și stabilitate. Am urmărit trei lucruri: ce se întâmplă dacă eliminăm grupuri întregi de caracteristici, ce coeficienți primește regresia logistică și dacă mecanismul de atenție al modelului recurent pune accent pe anumite momente din secvență.

1. Ablația și extragerea coeficienților

Pentru a înțelege importanța fiecărei trăsături, am analizat coeficienții atribuiți de regresia logistică. În paralel, am implementat un studiu de ablație. Am împărțit caracteristicile în cinci tipuri după rolul lor în analiză: dinamică oculară (*gaze dynamics*), explorare

spațială (*spatial search*), structură/entropie (*entropy structure*), contactul cu personajul și alinierea cu *saliency*. Apoi, am reantrenat modelul excluzând iterativ câte un grup, pentru a măsura impactul direct asupra performanței de clasificare (Figura 4a). Coeficienții regresiei logistice pentru predicția succesului sunt detaliați în Tabela 4 din anexe.

Rezultatele sunt compatibile cu observațiile deduse în etapa de analiză exploratorie:

- Excluderea informațiilor despre contactul direct cu personajul penalizează cel mai mult modelul pentru predicția succesului, reducând *balanced accuracy* cu 0.230.
- Eliminarea metricilor de entropie reduce *balanced accuracy* cu 0.120 pentru anticiparea unei căutări lungi.
- O observație importantă apare la excluderea datelor legate de *saliency*. Fără aceste date la antrenament, performanța modelului din ablație nu a scăzut, ci a crescut față de modelul complet al ablației, de la 0.689 la 0.764. Având în vedere setul restrâns de date, acest rezultat trebuie tratat mai degrabă ca o tendință, nu ca o regulă generală. Totuși, el arată că într-o sarcină ghidată strict de intenție (*top-down*), culorile stridente pot acționa ca zgomot, afectând stabilitatea modelului.

2. Mecanismul de atenție (BiLSTM)

Pentru modelul recurent, am extras ponderile generate de mecanismul de atenție (prin funcția *Softmax*) pentru a verifica dacă modelul tratează diferit pașii din secvență. Această verificare a fost folosită ca analiză a modelului, însă rezultatul principal rămâne comparația de performanță din Tabela 3: pe setul actual, *BiLSTM + Attention* nu depășește modelul simplu bazat pe serii de timp.

3. Analiza de stabilitate

În final, ca să verificăm stabilitatea rezultatelor, am eliminat din antrenament și testare sesiunile cu zgomot: cele cu peste 5% din fixații în afara ecranului sau cu *timestamp*-uri trunchiate. După reantrenarea modelelor pe aceste date filtrate, *balanced accuracy* a rămas apropiat de scorul inițial (în anexă, Figura 4b). Acest test sugerează că rezultatele reflectă tipare de explorare vizuală și nu doar erori de înregistrare ale *eye-tracker*-ului.

10 Concluzii

Teza a urmărit ambele obiective: am transformat înregistrările într-un set de date utilizabil, am explicat comportamentul vizual într-o sarcină de căutare și am arătat că aceste strategii pot fi analizate și modelate algoritmic.

Concluziile principale, susținute direct de date, sunt următoarele:

- **Căutarea orientată pe scop:** Participanții nu caută la întâmplare și nu sunt ghidați în principal de culorile stridente ale nivelului. Atât calculul *Information Gain* pe hărțile de *saliency*, cât și testele de ablație au arătat că aceste indicii vizuale pot introduce zgomot în model atunci când jucătorul are un obiectiv clar de rezolvat (*top-down*).
- **Acuratețea modelelor simple:** Pe un set de date redus, limitat la primele secunde de înregistrare, algoritmi clasici (regresia logistică și lanțurile Markov) au obținut rezultate mai bune decât rețelele recurente. În lipsa unui volum mare de date, arhitecturile complexe sunt mai expuse la *overfitting*, în timp ce modelele simple au generalizat mai bine pe setul nostru de date. Această concluzie este însă strâns legată de dimensiunea mică a eșantionului și ar trebui reconfirmată pe un volum mai mare de date.
- **Variabilitatea stilului de explorare:** Deși o sarcină de tip *Find Waldo* impune un anumit traseu vizual dictat de nivel, participanții își mențin un stil individual de căutare. Analiza a arătat că metrici precum ritmul fixațiilor și entropia spațială conțin diferențe comportamentale între participanți, independente de dificultatea nivelului.

Pe viitor, dezvoltarea firească a proiectului este extinderea setului de date. Un volum mai mare ar permite antrenarea unor arhitecturi *Deep Learning* mai complexe și extragerea unor dependențe pe termen lung. De asemenea, colectarea datelor în sesiuni multiple (*cross-session*), pe parcursul mai multor zile, ar ajuta la verificarea stabilității în timp a acestor stiluri individuale de explorare.

Bibliografie

- [1] Gary Bradski, „The OpenCV Library”, în *Dr. Dobb's Journal of Software Tools* (2000).
- [2] Zoya Bylinskii, Tilke Judd, Aude Oliva, Antonio Torralba și Frédo Durand, „What do different evaluation metrics tell us about saliency models?”, în *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41.3 (2019), pp. 740–757, DOI: [10.1109/TPAMI.2018.2815601](https://doi.org/10.1109/TPAMI.2018.2815601).
- [3] Andrew T. Duchowski, *Eye Tracking Methodology: Theory and Practice*, 3rd, Springer, 2017.
- [4] Martin Ester, Hans-Peter Kriegel, Jörg Sander și Xiaowei Xu, „A density-based algorithm for discovering clusters in large spatial databases with noise”, în *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 1996, pp. 226–231.
- [5] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke și Travis E. Oliphant, „Array programming with NumPy”, în *Nature* 585.7825 (2020), pp. 357–362, DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [6] John M. Henderson și Taylor R. Hayes, „Meaning guides attention in real-world scene images: Evidence from eye movements and meaning maps”, în *Journal of Vision* 18.6 (2018), 10:1–10:19, DOI: [10.1167/18.6.10](https://doi.org/10.1167/18.6.10).
- [7] Sture Holm, „A simple sequentially rejective multiple test procedure”, în *Scandinavian Journal of Statistics* 6.2 (1979), pp. 65–70.
- [8] John D. Hunter, „Matplotlib: A 2D graphics environment”, în *Computing in Science & Engineering* 9.3 (2007), pp. 90–95, DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).

- [9] Laurent Itti, Christof Koch și Ernst Niebur, „A model of saliency-based visual attention for rapid scene analysis”, în *IEEE Transactions on Pattern Analysis and Machine Intelligence* 20.11 (1998), pp. 1254–1259, DOI: [10.1109/34.730558](https://doi.org/10.1109/34.730558).
- [10] Marcel A. Just și Patricia A. Carpenter, „A theory of reading: From eye fixations to comprehension”, în *Psychological Review* 87.4 (1980), pp. 329–354, DOI: [10.1037/0033-295X.87.4.329](https://doi.org/10.1037/0033-295X.87.4.329).
- [11] Wes McKinney, „Data structures for statistical computing in Python”, în *Proceedings of the 9th Python in Science Conference*, 2010, pp. 56–61.
- [12] Jorge Otero-Millan, Stephen L. Macknik, Rachel E. Langston și Susana Martinez-Conde, „Micro and regular saccades across the lifespan during a visual search of “Where’s Waldo” puzzles”, în *Vision Research* 118 (2016), pp. 144–157, DOI: [10.1016/j.visres.2015.05.013](https://doi.org/10.1016/j.visres.2015.05.013).
- [13] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai și Soumith Chintala, „PyTorch: An imperative style, high-performance deep learning library”, în *Advances in Neural Information Processing Systems 32*, 2019, pp. 8024–8035.
- [14] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort et al., „Scikit-learn: Machine Learning in Python”, în *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.
- [15] Pupil Labs, *Neon Player Documentation*, Disponibil la <https://docs.pupil-labs.com/neon/>, Accesat la 08 iunie 2026.
- [16] Skipper Seabold și Josef Perktold, „Statsmodels: Econometric and Statistical Modeling with Python”, în *Proceedings of the 9th Python in Science Conference*, 2010, pp. 92–96.

- [17] Claude E. Shannon, „A mathematical theory of communication”, in *Bell System Technical Journal* 27.3 (1948), pp. 379–423, DOI: [10.1002/j.1538-7305.1948.tb01338.x](https://doi.org/10.1002/j.1538-7305.1948.tb01338.x).
- [18] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant et al., „SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python”, in *Nature Methods* 17 (2020), pp. 261–272, DOI: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [19] Michael L. Waskom, „Seaborn: Statistical Data Visualization”, in *Journal of Open Source Software* 6.60 (2021), p. 3021, DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021).
- [20] Jeremy M. Wolfe, „Visual Search: How Do We Find What We Are Looking For?”, in *Annual Review of Vision Science* 6 (2020), pp. 539–562, DOI: [10.1146/annurev-vision-091718-015048](https://doi.org/10.1146/annurev-vision-091718-015048).
- [21] Alfred L. Yarbus, *Eye Movements and Vision*, New York: Plenum Press, 1967.

A Anexe

A.1 Rezultatele modelării

Tabela 3: Performanța modelelor evaluată pe ferestre de 5 secunde. *Balanced accuracy* este metrica principală.

Abordare	Sarcină / Model	Balanced Acc.	Scor F1
Clasic	Predicția Succesului		
	<i>Majority</i>	0.500	0.849
	Regresie Logistică (<i>gaze only</i>)	0.459	0.678
	Regresie Logistică (<i>gaze + target</i>)	0.705	0.814
Clasic	Predicția Căutării Lungi		
	<i>Majority</i>	0.409	0.000
	Regresie Logistică (<i>gaze only</i>)	0.693	0.698
	Regresie Logistică (<i>gaze + target</i>)	0.598	0.605
Recurent	Predicția Succesului		
	<i>Time-Averaged MLP</i>	0.572	0.750
	<i>BiLSTM + Attention</i>	0.511	0.787
Recurent	Predicția Căutării Lungi		
	<i>Time-Averaged MLP</i>	0.792	0.765
	<i>BiLSTM + Attention</i>	0.589	0.579
Tranziție	Predicția Următoarei Mișcări		
	<i>Majority</i>	0.250	0.136
	<i>MLP Tranziție</i>	0.586	0.591
	Lanț Markov (ordin 1)	0.643	0.641


A.2 Coeficienții modelului liniar (Sarcina de succes)

În completarea analizei de ablație de la secțiunea de Interpretabilitate, Tabela 4 arată caracteristicile cu cele mai mari valori ale coeficienților în regresia logistică. Numele din tabel sunt cele interne ale trăsăturilor folosite în cod. Semnul coeficientului arată direcția relației cu predicția succesului: valorile pozitive cresc logitul pentru succes, iar cele negative îl scad.


Tabela 4: Caracteristicile folosite în regresia logistică pentru predicția succesului.

Caracteristică	Coeficient	Direcție
<code>early_spatial_coverage_hull</code>	-1.554	negativă
<code>early_total_fix_duration_s</code>	1.388	pozitivă
<code>early_gaze_entropy</code>	1.330	pozitivă
<code>early_gaze_count</code>	-1.297	negativă
<code>early_saccade_length_avg</code>	1.291	pozitivă
<code>early_scanpath_length_per_s</code>	-1.157	negativă
<code>early_direct_hit_count</code>	1.155	pozitivă
<code>early_hit_any</code>	1.152	pozitivă

A.3 Rezultate suplimentare pentru interpretabilitate



(a) Ablație pe grupuri



(b) Stabilitatea la filtrarea zgomotului

Figura 4: Graficul din stânga arată modificarea performanței atunci când un grup de caracteristici este eliminat. Valorile pozitive înseamnă că performanța scade după eliminare, deci grupul era util. În dreapta, rezultatele arată că modelele își păstrează performanța chiar și după ce înregistrările cu erori de la *eye-tracker* sunt eliminate din setul de date.

A.4 Verificări vizuale ale datelor




Figura 5: Indicatorii de calitate ai datelor per participant. Valorile rămân reduse pentru toți participanții.




Figura 6: Variația timpului de căutare pe participant. Fluctuațiile mari arată că timpul depinde foarte mult de dificultatea nivelului, nu doar de cât de rapid este participantul.



Figura 7: Exemplu de hartă de atenție (KDE) suprapusă peste nivel

A.5 Matricele de tranziție spațială pe nivel

Pentru a detalia vizual calculul entropiei de tranziție (Secțiunea 5) și rezultatele modelului Markov (Secțiunea 8), Figura 8 ilustrează probabilitățile de trecere între cele 4 cadrane ale ecranului (grila 2×2 folosită de modelul Markov din Secțiunea 8; entropia de tranziție din Secțiunea 5 este calculată separat, pe grila de 4×4). Pe toate nivelurile, probabilitatea cea mai mare rămâne pe diagonală, ceea ce arată că privirea tinde să rămână în același cadran între două tranziții consecutive.






Figura 8: Matricele de tranziție agregate pe nivel (4 cadrane).

A.6 Rezultate suplimentare pentru diferențele individuale

În completarea Secțiunii 7, Tabela 5 arată rezultatele clasificării exploratorii între participanți. Fiecare rând folosește un alt subset de caracteristici normalizate pe nivel. Rezultatele arată că includerea tuturor metricilor introduce zgomot, performanța optimă fiind obținută printr-un subset restrâns de patru caracteristici.



(a) Caracteristici comportamentale normalizate



(b) Variația explicată de participant


Figura 9: Diferențe individuale după normalizarea pe nivel. În stânga, fiecare celulă arată abaterea participantului față de mediana nivelului pentru o anumită metrică. În dreapta, barele arată cât crește R^2 atunci când participantul este adăugat peste modelul bazat doar pe nivel.

Tabela 5: Performanța clasificării exploratorii între participanți pentru mai multe subse-uri de caracteristici.


Reprezentare	Nr. caract.	Accuracy	Balanced accuracy
Top 4 caracteristici individuale	4	0.350	0.318
Top 5 caracteristici individuale	5	0.325	0.295
Top 8 caracteristici individuale	8	0.325	0.295
Scoruri comportamentale agregate	4	0.275	0.250
Toate metricile	14	0.250	0.227
Explorare largă	5	0.225	0.205
Focus pe țintă	5	0.200	0.182
Ritm vizual	3	0.200	0.182

Raportat la probabilitatea aleatoare de ≈ 0.091 (aferentă celor 11 clase), valoarea maximă de *balanced accuracy*, 0.318, susține observațiile anterioare. Mai exact, ritmul fixațiilor, lungimea traseului raportată la timp, timpul alocat țintei și entropia spațială reprezintă principalele ancoră comportamentale care diferențiază participanții în această sarcină.

Mai departe, Figura 10 detaliază aceeași analiză. Graficul din stânga grupează metri-cile în: explorare extinsă, orientare eficientă, focus pe personaj și ritm vizual. Unele bare pot lipsi sau pot fi aproape de zero atunci când scorul participantului este foarte apropiat de media setului. Matricea din dreapta este matricea de confuzie pentru clasificarea între participanți.



(a) Scoruri comportamentale pe participant



(b) Matrice exploratorie de confuzie

Figura 10: Detalierea diferențelor individuale. Figura din stânga arată scorurile comportamentale per participant, iar matricea din dreapta arată unde clasificarea confundă participanții între ei.